Chatbot do Kronos

Feito por:
Giovanna Pelati
Júlia Penna
Dmitri Kogake
Theo Correia

2°I

DESCRIÇÃO DO PROJETO

Visão geral

O Chatbot do Kronos foi desenvolvido com o objetivo de criar um assistente virtual inteligente integrado ao aplicativo Kronos, um sistema de gerenciamento de tarefas fabris que organiza a rotina diária dos funcionários, melhora a produtividade e garante a continuidade dos processos industriais.

Atuação do chatbot

O chatbot atua como um guia interativo, auxiliando usuários iniciantes a se familiarizarem com o aplicativo e suas funcionalidades, utilizando linguagem acessível e respostas precisas.

TECNOLOGIAS UTILIZADAS

Tecnologia	Uso no Projeto
gemini-2.0-flash / gemini-2.5-flash	LLMs para geração de respostas e moderação
LangChain	Framework de orquestração dos agentes
gemini-embedding-001	Geração de embeddings para RAG
MongoDB	Armazenamento de histórico e base de conhecimento
FastAPI + Render	API e hospedagem

OBJETIVO DO SISTEMA

O chatbot foi projetado para responder dúvidas sobre o uso do aplicativo Kronos, como:

Como posso desatribuir uma tarefa?

Como envio um arquivo para justificar minha ausência?

Como funciona a análise GUT?

Além disso, ele deve identificar perguntas inadequadas, manter o contexto da conversa e gerar respostas coerentes e seguras.

ARQUITETURA GERAL

O chatbot é composto por três agentes que operam em sequência dentro de uma pipeline de execução:

Agente	Função	Modelo e Configuração	Formato de Saída
Guardrail	Atua como filtro de segurança, validando se a entrada do usuário é apropriada.	gemini-2.0-flash e temperatura 0 (respostas determinísticas e rápidas).	Retorna um JSON estruturado indicando se a entrada é válida ou inválida, junto de uma mensagem educada quando necessário.
Escritor	Utiliza o serviço de Recuperação de Contexto (RAG) para buscar informações relevantes no banco e gerar a resposta final.	gemini-2.5-flash e temperatura 0.3 (respostas mais elaboradas e contextuais).	Retorna a resposta final ao usuário com base no contexto recuperado.
Juiz	Valida e refina a resposta gerada, garantindo coerência, clareza e conformidade com o contexto.	gemini-2.0-flash e temperatura 0 (respostas determinísticas e rápidas).	Retorna um JSON estruturado indicando se a resposta é válida ou inválida, junto de uma correção quando necessário.

Fluxograma de Arquitetura do Chatbot

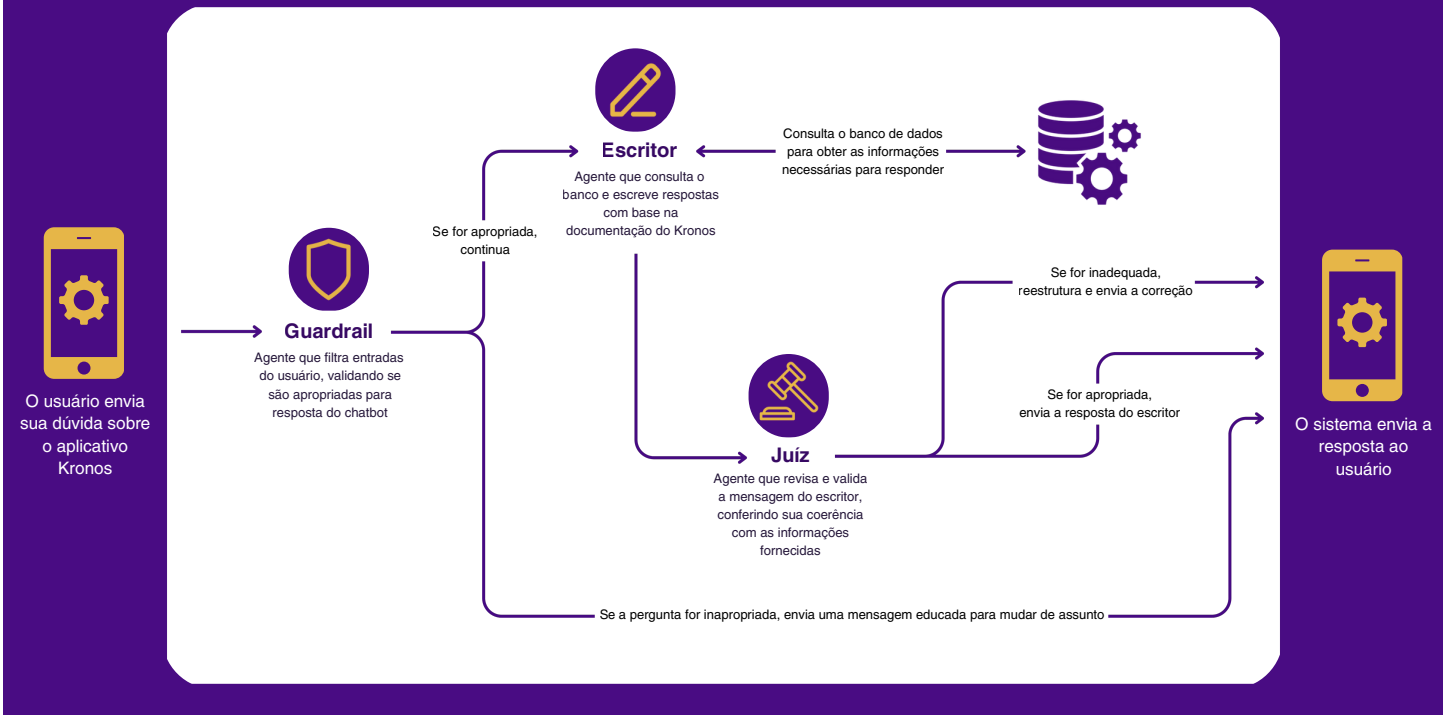

EXEMPLOS DE RESPOSTA

Input	Output
Como posso desatribuir uma tarefa?	Se você precisar que uma tarefa seja desatribuída por não pertencer a você, por não compreendê-la ou por ter algum impedimento em sua execução, você pode reportá-la. Para fazer isso, clique no **ícone de atenção** ⚠️ associado à tarefa. Ao reportar, a tarefa será enviada para análise do seu gestor.
Como envio um arquivo para justificar minha ausência?	Para enviar um arquivo e justificar sua ausência, você deve ir ao calendário 🗓️. Lá, ao registrar sua ausência, você terá a opção de anexar arquivos, como fotos de atestados médicos.
Como funciona a análise GUT?	A análise GUT funciona avaliando as tarefas com base em três critérios principais: gravidade, urgência e tendência. Cada um desses critérios é classificado em uma escala de 1 a 5, onde 1 representa o nível mais baixo e 5 o mais alto. Essa avaliação ajuda a priorizar as tarefas, organizar melhor o tempo de execução e focar no que é mais importante 📊.

ESTRUTURA DE PASTAS E ARQUIVOS

/kronos-chatbot

```
|
├── agents/     Contém a lógica de cada agente.
|   ├── guardrail_agent.py
|   ├── judge_agent.py
```

```
│   ├── rag_agent.py
│   └── prompts/     Contém os prompts de configuração.
│       ├── guardrail/
│       ├── judge/
│       └── rag/
│           ├── fewshots.json     Cada agente possui few-shots.
│           └── system_prompt.txt     Cada agente possui um prompt de sistema.
│
├── db_scripts/     Scripts de banco de dados e documentos base.
│   ├── docs.json     Base de conhecimento (FAQ).
│   ├── populate_db.py     Popula o MongoDB com os documentos.
│   └── generate_embeddings.py     Cria embeddings vetoriais com gemini-embedding-001.
│
├── services/     Serviços auxiliares do chatbot.
│   ├── memory_service.py     Recupera o histórico de conversas no MongoDB.
│   └── rag_service.py     Fluxo RAG com cosine similarity, retorna os top 3 resultados.
│
├── tests/     Conjunto para testes automáticos.
│   ├── questions/
│   ├── answers/
│           ├── default.json     Testes com perguntas padrão do FAQ.
│           └── exception.json     Testes com entradas inadequadas.
│           ├── memory.json     Testes de memória de sessão.
│           └── hallucination.json     Testes de verificação de alucinações.
│   └── tests.py     Script que executa as perguntas e armazena as respostas no answers/.
│
```

```
├── docs/     Documentação do chatbot.
│   ├── estrutura_de_agentes.png     Imagem do Fluxograma de Arquitetura.
│   └── entrega_do_chatbot.pdf     Este arquivo!
│
├── pipeline.py     Define a execução sequencial dos agentes e o tratamento de histórico.
└── main.py     Implementa as rotas da API usando FastAPI.
```

INFORMAÇÕES ADICIONAIS

Formato de Saída do Guardrail e Juiz

Os dois agentes seguem o mesmo padrão básico: outputs estruturados em JSON com dois campos, "flag" e "message".

No Guardrail:

- "flag": indica se a entrada é válida.
  - 0 → entrada válida
  - 1 → entrada inválida ou ofensiva
- "message": mensagem educada orientando o usuário a mudar de assunto; retorna None quando "flag" = 0.

No Juiz:

- "flag": indica se a resposta do Escritor é adequada.
  - 0 → resposta adequada
  - 1 → resposta inadequada
- "message": resposta reestruturada e corrigida; retorna None quando "flag" = 0.

Dessa forma, os retornos garantem padronização e clareza na comunicação entre os agentes, além de assegurar a condução coerente e controlada do fluxo de respostas.

Histórico de Conversas

Além de armazenar o FAQ, o MongoDB também é responsável por registrar o histórico de conversas do chatbot.

Por meio da classe MongoDBChatMessageHistory, cada interação recebe um session_id único, e as mensagens do usuário e do chatbot são salvas na coleção conversations. Durante a execução do arquivo pipeline.py, o histórico é atualizado sempre que o usuário envia uma pergunta ou um agente gera uma resposta. Cada documento armazena uma mensagem enviada.